Домашние растения: дообучение и оценка Qwen2.5

Итоговый отчёт · 5 ноября 2026 года · эксперимент 0e734bee13c1

1. Задача, гипотеза и первые ответы

Разработан русскоязычный текстовый помощник по уходу за домашними растениями. Вопрос содержит вид, условия или симптом; ответ должен давать понятный порядок действий и обозначать недостающие сведения. Темы: полив, свет, пересадка, питание, размножение и типичные проблемы. Фотографии, RAG и пользовательский интерфейс в этот этап не входят.

Гипотеза: SFT на тематическом наборе улучшит соблюдение структуры и полезность ответов. Базовая модель — **Qwen/Qwen2.5-3B-Instruct**, отдельный судья — Qwen2.5-7B-Instruct. До и после применены один системный промпт, 4-битное NF4-квантование и greedy decoding с лимитом 384 токена. Опорные факты из test доступны только оценщику.

Что получилось. Проведены первые генерации, пробное и основное обучение на T4, загрузка адаптера, автоматическая и модельная оценка до/после. Соблюдение формата на 36 вопросах выросло с 31 до 36 ответов. При этом содержательные ошибки сохранились, а в оценках судьи найдены приписанные ответам утверждения. Гипотеза подтверждена для структуры на этом тесте; общего улучшения предметной полезности доказать не удалось.

Первый прогон до обучения

Вопросы взяты из validation. Полные сообщения и ответы сохранены в results/experiment/baseline_validation.jsonl.

Вопрос	Наблюдение по исходному ответу
Монстера: сверху сухо, глубже сыро. Уже поливать?	Предложен полив по сухому верхнему слою и странная проверка «глубины впитывания». Влага глубже учтена плохо. Формат соблюдён.
Сансевиерия: прихожая без окна и лампы. Допустимо?	Рекомендована досветка, но добавлено опрыскивание без основания. Заголовок «Краткие рекомендации» нарушил заданный формат.

Эти случаи показывают различие структуры и содержания: первый ответ проходит формальную проверку, но не становится от этого предметно правильным. Первый judge-прогон дал обоим ответам корректность 3/5 и полезность 5/5 — уже на пилоте заметна мягкость оценки полезности.

2. Данные и разбиение

Создан авторский синтетический набор: 12 растений × 12 типов задач = **144 исходные ситуации**. Профили и вопросы находятся в data/profiles.json; сборка — python -m src.prepare_data. Ответы составлены из кратких правил и видовых фактов с ссылками на NC State Extension, UC IPM, университетские справочники и RHS. Полные статьи и изображения не копировались. Происхождение записей явно указано: assistant_authored_rule_composition.

Часть	Строк	Исходных ситуаций	Назначение
Train	288	96	Обучение; по 3 формулировки вопроса
Validation	12	12	Контроль и выбор checkpoint
Test	36	36	Финальное сравнение двух версий

На каждое растение приходится 8 train-, 1 validation- и 3 test-ситуации. Темы сбалансированы: по 3 тестовых вопроса на тип задачи. Три train-формулировки не считаются независимыми примерами. Первоначальный ориентир на 1000 записей сокращён: дополнительные шаблонные строки увеличили бы объём, но не покрытие фактов.

В JSONL есть id, group_id, plant, topic, messages, source_ids, опорные факты и перечень существенных ошибок. Роли в messages: system, user, assistant. Все три файла загружены через datasets.load_dataset("json", ...). Trainer читает только train/validation; генератор — только system/user.

Пример обучающего материала

monstera_light_v0: «Хочу переставить молодую монстеру на южный подоконник без тюля. Как сделать это без ожогов?» Основные элементы ответа: постепенная адаптация, рассеянный свет, наблюдение за новыми повреждениями, уточнение длительности прямого солнца. Эталон оформлен тремя заданными разделами и списком действий; полностью доступен в JSONL.

Проверки и ограничения

До обучения зафиксировано разбиение. Группы перефразировок не пересекаются; проверены уникальность id, точные дубли вопросов, роли, источники и структура эталонов. При символьной близости вопросов выше 0,82 совпадений между train и validation/test не найдено. Это ограниченная эвристика, а не доказательство отсутствия семантических повторов.

Общие шаблоны ответов и правила остаются во всех частях. Поэтому измеряется перенос между комбинациями растения и задачи внутри синтетического распределения. Набор не заменяет реальные обращения; независимой ботанической разметки нет. После просмотра test веса и настройки не менялись.

3. Автоматическая проверка

Реализована validate_format(answer) в src/checks.py. Она требует:

1. По одному разделу «Краткий ответ», «Рекомендации», «Что уточнить», в указанном порядке. 2. Непустое содержимое разделов. 3. От двух до пяти непустых пунктов в рекомендациях.

Допускаются Markdown-заголовки и маркированные/нумерованные списки. Проверка возвращает результат и причины отказа. Это полезно для темы ухода: пользователю важно отделить вывод, действия и уточнения. Проверка не оценивает правильность советов, русский язык, грамматику или отсутствие лишних фраз.

Проверенные срабатывания

Случай	Ожидание	Фактически
Корректные три раздела и два пункта	Пропуск	Пропуск
Те же разделы с Markdown	Пропуск	Пропуск
Пропущен раздел	Отказ	Отказ
Пустой раздел	Отказ	Отказ
Рекомендации абзацем без списка	Отказ	Отказ
Повтор заголовка	Отказ	Отказ
Неправильный порядок	Отказ	Отказ

Все семь случаев выполнены; данные сохранены в results/check_examples.json. Дополнительно проверены пустые пункты, маски токенов, подсчёт метрик при пропусках, повторные оценки и упаковка артефактов. Всего локально прошли 15 проверок; отдельно — CPU-интеграция с маленькой случайной Qwen2. Она проверяла код, а не качество обученной 3B-модели.

Пример реального отказа и метрика

В ficus_drainage_v0 baseline использовал «Краткие рекомендации» вместо «Рекомендации»: проверка отказала. После SFT заголовок исправился. При этом обе версии советовали слить воду; исправление заголовка не доказывает улучшения самого совета.

Метрика: число прошедших ответов / число всех тестовых вопросов. Ошибка генерации остаётся в знаменателе. Получено **31/36 = 86,11% до** и **36/36 = 100% после**, прирост **13,89 процентного пункта**. Ошибок исполнения и обрезанных ответов нет.

Полнота структуры стала лучше на данном тесте. Но фразы вроде «мягкие твёрдые листья» проходят эту проверку: её область применения намеренно узкая.

4. Модель-судья и протокол оценки

Судья — отдельная **Qwen2.5-7B-Instruct**, загруженная последовательно после освобождения GPU. API-ключ не нужен. Судья получает вопрос, ответ, опорные факты и типичные существенные ошибки. Версия отвечавшей модели скрыта, задания перемешаны с seed=42. Полный промпт — prompts/judge.txt; запросы, исходные ответы и ревизии сохранены в JSONL.

Критерий	Что оценивается
Correctness	Соответствие фактам, отсутствие существенной ошибки
Usefulness	Понятные применимые действия
Context	Учёт условий и необходимой неопределённости
Consistency	Согласованность рекомендаций

По каждому критерию используются целые баллы 1–5: 1 означает серьёзную проблему, 3 — частичное выполнение, 5 — отсутствие замеченной проблемы. Промежуточные 2 и 4 допустимы. Отдельно возвращаются critical_error и объяснение. Невалидный JSON можно исправить одной повторной попыткой; пропуски учитываются через покрытие.

Выполненные вызовы

Пилот: два исходных validation-ответа до обучения. Затем — 24 validation-оценки суммарно и 72 основные test-оценки. Для шести test-заданий выполнен повтор с обратным порядком полей контекста. Все 102 сохранённых результата валидны с первой попытки; исходные JSON совпадают с распарсенными баллами. Покрытие test — 36/36 для обеих версий.

Повторная проверка не является независимым судейством. Среднее абсолютное изменение баллов при перестановке полей — **0,417** по четырём критериям и шести ответам. В двух заданиях числовые оценки изменились. Например, у spider_specific_v0 корректность baseline упала с 5 до 3 при неизменном ответе.

Как интерпретировать

Судья из того же семейства может иметь общее смещение с базой. Высокая полнота JSON не гарантирует правильной оценки. После запуска выполнен содержательный разбор всех 36 пар помощником, без независимого ботанического эксперта. Выявлена конкретная проблема: судья переносит некоторые примеры ошибок из справочного контекста в обвинения оцениваемому ответу. Подробности приведены в разделе 7.

Оценки не исправлялись задним числом: исходные числа сохранены и опубликованы как результат выбранного протокола вместе с обнаруженными ограничениями.

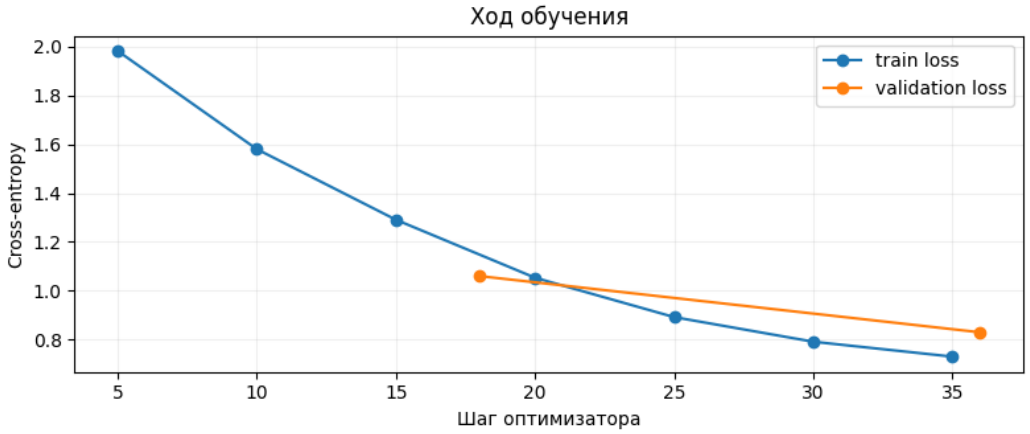
5. Обучение на T4 и ход эксперимента

Подтверждённая среда: **Tesla T4**, 14,56 GiB памяти, Python 3.13.16, PyTorch 2.8.0, Transformers 4.56.2, PEFT 0.17.1, bitsandbytes 0.47.0. Базовая ревизия: aa8e72537993ba99e69dfaafa59ed015b17504d1; судья: a09a35458c702b33eeacc393d103063234e8bc28.

Параметр	Значение
Метод	QLoRA, NF4 + double quantization, вычисления FP16
LoRA	rank 16, alpha 32, dropout 0,05; 7 типов линейных слоёв
Batch / накопление	1 / 16
Learning rate / scheduler	0,0001 / cosine; warmup 0,03
Эпохи / шаги	2 / 36
Длина / seed	1024 / 42
Выбор checkpoint	Минимум validation loss; checkpoint-36

Использованы Transformers Trainer и явная маска: system/user исключены из loss, assistant и токен его завершения включены; padding имеет label=-100. Слишком длинные примеры не обрезаются молча. Реальный максимум train — 522 токена, медиана 465. Обучаемых токенов ответов в train — 53 322 на проход.

Перед длительным запуском выполнены два пробных шага и загрузка пробного адаптера новым процессом. Основное обучение заняло **13.92 мин**. Пик по torch.cuda.max_memory_allocated — **4.37 GiB**; это выделения PyTorch, а не полное потребление всей видеопамяти. Validation loss снизился с 1,061 после первой эпохи до 0,831 после второй.



Первый запуск прервался при скачивании судьи с IncompleteRead / ChunkedEncodingError. Повторный запуск использовал кэш и сохранённые этапы, затем прошёл весь pipeline. Добавлена подготовка загрузки с одним потоком и ограниченными сетевыми повторами. В сыром state.json осталась историческая ошибка, но итоговый статус — computed, все 15 стадий завершены.

6. Количественные результаты

Обе версии отвечали на **одни и те же 36 test-вопросов**. Ни один ответ не потерян и не обрезан. Для всех получены валидные оценки, поэтому общий набор пар также равен 36. Метрики и bootstrap-интервалы независимо пересчитаны из сохранённых JSONL и точно совпали с Colab.

Показатель	До	После	Разность	95% интервал разности
Формат, %	86.11	100.00	+13.89	[+5.56; +22.22]
Корректность, 1–5	3.39	3.83	+0.44	[-0.17; +1.22]
Полезность, 1–5	4.47	4.67	+0.19	[-0.31; +0.67]
Учёт условий, 1–5	4.08	4.22	+0.14	[-0.36; +0.67]
Согласованность, 1–5	3.83	4.39	+0.56	[-0.17; +1.28]
Флаг critical_error, %	19.44	2.78	-16.67	[-30.56; -5.56]

Для долей разность и интервал указаны в процентных пунктах. Использован парный cluster bootstrap по 12 растениям, 2000 повторов, seed=42. Это описательные интервалы малого синтетического набора; общие шаблоны и корреляция тем ограничивают перенос на реальные вопросы.



Формат улучшился на данном тесте: исправились все пять нарушений baseline. Средние четырёх качественных оценок судьи выросли, но каждый соответствующий интервал содержит ноль. Устойчивое повышение предметного качества на этих данных не доказано.

Флаг судьи critical_error снизился с 7/36 до 1/36. Это **число выставленных судьёй флагов**, не установленная частота опасных советов. Из-за ошибок его объяснений даже интервал, не содержащий ноль, не доказывает уменьшения реального вреда. Отдельная проверка этого ограничения — следующий раздел.

7. Проверка достоверности оценок судьи

Просмотрены все 36 пар ответов и объяснения судьи. Разбор записан в results/qualitative_review.json. Это содержательный аудит помощником после завершения test, а не независимая экспертная разметка и не новая итоговая метрика.

Приписанные утверждения

Ситуация	Что утверждает судья	Что есть в исходном ответе
aloe_pests_v0, baseline	Совет смешивать бытовую химию	Есть общая обработка инсектицидом; смешивания нет
ficus_drainage_v0, baseline	Камни полностью заменяют слив	Прямо предложено слить оставшуюся воду; камни не обсуждаются
snake_repot_v0, baseline	Обязательно взять горшок без отверстий	Такого совета нет; реальная проблема — чрезмерное увеличение размера

Из семи baseline-флагов существенной ошибки **в пяти объяснениях указанное утверждение отсутствует в ответе**. Это не означает, что все пять ответов правильные: например, слишком большой горшок остаётся настоящей проблемой. Вывод уже: нельзя считать эти объяснения доказательством выставленного флага.

Наблюдение согласуется с переносом текста из critical_mistakes в оценку ответа: про камни и смешивание химии сказано в справочном контексте. Причинный механизм не доказан отдельным экспериментом, поэтому это объяснение рассматривается как гипотеза.

Высокий балл при плохом ответе

zz_light_v0 после SFT получил 5/5 по всем критериям, хотя содержит английскую фразу и совет оценить свет «через призму». В ficus_wet_v0 повторяется «мягкие твёрдые листья», но согласованность оценена на 5/5. В orchid_light_v0 нет ясной защиты от прямого солнца, а оценка после SFT снова максимальная.

И наоборот, у jade_drainage_v0 baseline с неудачным советом частого обильного полива получил 5/5, а более уместный SFT-совет о сливных отверстиях — 3/5 за корректность.

Решение по интерпретации: сохранить исходные оценки, но опираться в основном выводе на независимо проверенный формат и конкретные пары ответов. В будущем судье нужны подтверждающие цитаты из ответа, проверка их присутствия и независимая калибровка; такой новый протокол потребует отдельного эксперимента.

8. Качественные изменения: улучшения и сохраняющиеся ошибки

Пример улучшения: сансевиерия зимой

Вопрос: «На холодном подоконнике сансевиерию поливают как летом. Что следует проверить?»

До: «Поливайте сансевиерию через день, но не допускайте переувлажнения».

После: «Оцените вес горшка и состояние кома, а не только внешний вид листьев»; после полива предложено слить воду.

Необоснованный частый график исчез. Это согласуется с потребностью осторожного полива и просушки в прохладных условиях [1]. Но фраза после SFT «при длительной потере суккулентов» бессодержательна: весь ответ нельзя считать качественным.

Пример улучшения: субстрат фаленопсиса

На вопрос о разрушившейся коре baseline предлагал оставить её в покое. После SFT: «Используйте специальную орхидеевую смесь с хорошим дренажом; не заменяйте её плотной землёй». Основное действие стало уместнее для эпифитной орхидеи [2].

Неустранённая ошибка: лист эпипремнума

На вопрос о листе без части побега baseline обещал новое растение. После SFT: «Есть способы размножения без прямого участка побега», далее — неясные советы про корни и узел. Ясное объяснение необходимости стеблевого узла с почкой не появилось [3]. Судья поставил после SFT 1/5 по всем критериям — здесь низкая оценка соответствует проблеме.

Потеря конкретного ответа

В monstera_specific_v0 baseline верно допускал цельные молодые листья как норму [4]. После SFT прямой ответ исчез за общими проверками. В spider_dry_v0 совет восстановить полив заменён общими рассуждениями и китайским фрагментом. В holiday_propagate_v0 вопрос укоренения веточки подменён диагностикой болезни.

Формально правильная структура не устранила языковые сбои. Дополнительный поиск китайских либо арабских символов дал по 2 ответа из 36 у обеих версий; это post-hoc наблюдение, а не полноценная метрика русского языка. Английские вставки такая эвристика не охватывает.

Полные исходные ответы всех 36 пар, баллы и комментарии вынесены в report/appendix_answers.md. Веса после этого разбора не переобучались.

9. Выводы, воспроизведение и артефакты

Основной результат: тематический QLoRA-SFT выполнен на T4 и улучшил заданную структуру на тесте с 86,11% до 100%. Подтверждения общего повышения предметной полезности недостаточно: качественные интервалы широкие, отдельные ответы ухудшились, а судья оказался ненадёжным в ряде объяснений. Это частичное подтверждение гипотезы, не отрицание выполненного обучения.

Практически удачные решения: ограниченный набор с явным происхождением; разбиение групп до обучения; одинаковая база и генерация; явная маска assistant; ранний sanity check; сохранение реальных ошибок и состояния; отдельный контроль качества оценщика. Неудачи: шаблонные данные, усреднённые и бессвязные ответы после SFT, смешение языков, переоценка полезности судьёй, прерванная сетевая загрузка.

Ограничения: 96 исходных train-ситуаций, один seed обучения, 12 validation- и 36 test-вопросов, общие шаблоны, отсутствие независимой ботанической экспертизы и один судья из того же семейства. Следующий эксперимент должен расширять реальные ситуации и проверять доказательность оценок. Подбор по уже просмотренному test недопустим.

Воспроизведение

Загрузить подготовленную папку dist/houseplants в корень Моего диска, открыть colab_pipeline.ipynb как блокнот, выбрать T4 и выполнить ячейки. Путь задаётся PROJECT_DIR; исходники копируются локально для скорости, результаты — в Drive. Повторный запуск продолжает сохранённые стадии. Для тех же моделей используются commit SHA из results/experiment/model_revisions.json.

Без повторного обучения: запустить scripts/verify_submission.py; метрики пересчитываются из сохранённых генераций, а safetensors проверяется без выполнения pickle-файлов. Полная среда Colab записана в results/experiment/pip-freeze.txt; adapter содержит 29 933 568 параметров в 504 тензорах. Все значения проверены на конечность. Загрузка адаптера поверх точной базовой ревизии показана в README.

Код, данные, ноутбук, логи, метрики, графики и отчёт доступны в репозитории wVks/houseplants. Обученный адаптер размещён через Git LFS; прямая ссылка на safetensors. Базовые 3B-веса не включены; лицензия qwen-research и Notice приложены. Built with Qwen. Для LMS сдаются ссылка на репозиторий и этот PDF. Отправка в LMS выполняется отдельно.

Основные источники

[1] NC State: Dracaena trifasciata.

[2] NC State: Phalaenopsis.

[3] University of Missouri: Home Propagation of Houseplants.

[4] NC State: Monstera deliciosa.

Другие видовые и технические источники: data/sources.jsonl, карточки Qwen2.5-3B/7B на Hugging Face, документация Transformers/PEFT. Дата обращения — 5 ноября 2026 года.